


سوال اول :

(الف) طبق فرمول برای به دست آوردن  $w$  باید به ویدئو با فیلتر ضرب شوند و در نهایت جمع شوند در نتیجه هر چه یک  $w$  بزرگتر باشد تأثیر آن فیلتر بیشتر می دهد اما در صورتی که فیلتر گفته شده با یایی و دیگر از فیلترها وابستگی بالا داشته باشد و ضریب آن مخالف فیلترهای با سطوح دیگر در یکدیگر واضح می باشد در نتیجه برای داشتن میزان اهمیت این ضریب میانه اطلاعات بیشتر داریم که ترکیبی سوم صحیح است.

(ب)

(a) طبق فرمول جمع داریم  $E_0(y(x; D)) - h(x)$  نتیجه هر چه مقدار دیتاست ها را بیشتر کنیم مقدار وابستگی به  $h(x)$  نزدیک تر می شود و در نتیجه با یاس ما کمتر خواهد شد پس هدف درست است.

(b) با کم کردن خطای  $training$  در دایره داریم مدل را به داده های ورودی فیت می کنیم در دایره  $trade off$  بین با یاس و دایره با یاس داریم با یاس را اتحاد ممکن کم کرده و دایره با یاس را زیاد می کنیم یعنی با اضافه شدن  $w$  داده ای برت مدل به آن داده فیت شده و مشعل ضرر کمتر می دهد تا آنکه در آن نقطه اندک باعث فراموشی مدل در  $over fit$  شدن آن می شود که گزاره غلط است.



(c) در این مثال اگر خطای هم خطای مدل و خطای  $w$  باید به گونه ای عمل کنیم که از نقطه های فیت بر دست زد در این صورت فضای  $x$  که داده ی ترین حالت شتر می شود ولی اگر سعی کنیم با یاس را کم کنیم برآوردیم مدل فضای شتر و فضای کمتر خواهد شد که گزاره غلط است.

(d) هسته فضای  $test$  یا در حالت پیچیده تر بین از اندازه سبک فضای  $test$  است مدل بیش از اندازه ساده باشد و نتوانسته باشد به خوبی یاد بگیرد و نیاز است که مدل را پیچیده تر کنیم که گزاره غلط است.

سوال ۲ :

(a) برای اینکه  $w_{opt}$  را به دست آوریم باید خطای کمینه کنیم

$$\min E = \sum_{n=1}^N (y_n - w^T x_n)^2$$

$$\rightarrow \nabla E = 2 \sum_{n=1}^N (y_n - x_n^T w) x_n = 0 \rightarrow \sum_{n=1}^N y_n x_n = w^T \sum_{n=1}^N x_n x_n^T$$

$x_n$  برداری است که مقادیر تابع  $linear$  به ازای هر  $x$  در آن قرار دارد در نتیجه  $x$  یک ماتریس است که در هر یک از  $N$  سطر آن یکی از  $x_n$  ها قرار دارد در نتیجه  $x$  ها را با ضرب ماتریسی جایگزین می کنیم:

$$X^T = \begin{bmatrix} x_1 & x_2 & \dots & x_N \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} \quad \rightarrow \quad \begin{bmatrix} \sum_{i=1}^N t_i x_i^1 \\ \vdots \\ \sum_{i=1}^N t_i x_i^M \end{bmatrix}$$

(M ضل برابر است)



می توان به آسانی در معادلات ماتریس معکوس می توان نوشت  $\sum_{n=1}^N y_n x_n$  است در واقع می توان معکوس می توان نوشت معادله را به  $X^T Y$  جایگزین کرد  
حال معکوس را به معادلات ماتریس معکوس می توان نوشت به معکوس می توان نوشت معادله را به  $X^T Y$  جایگزین کرد  
معکوس می توان نوشت  $(X^T X)^{-1}$  معکوس می توان نوشت  
در نتیجه داریم  $X^T Y = (X^T X) w \rightarrow w = (X^T X)^{-1} X^T Y$

(b) اگر ما را اضافه کنیم جمله در در معادله معکوس می توان نوشت در معادله معکوس می توان نوشت  $w$  با اضافه می توان نوشت

$$\min E = \sum_{n=1}^N (y_n - w^T x_n)^2 + \sum_{n=1}^N \lambda w_i^2$$

$$\nabla E \rightarrow X \sum_{n=1}^N (y_n - x_n^T w) x_n + 2 \lambda \sum_{n=1}^N w_i = 0 \rightarrow \sum_{n=1}^N y_n x_n = \sum_{n=1}^N \lambda w_i$$

در معادله معادله معکوس می توان نوشت

$$X^T Y = (X^T X) w + \lambda I w \rightarrow w = (X^T X + \lambda I)^{-1} X^T Y$$

(c) در این معادله معکوس می توان نوشت در معادله معکوس می توان نوشت

$$(X^T \Sigma^{-1} X)^{-1} X^T \Sigma^{-1} Y = (X^T X) X^T Y \leftrightarrow \sum X \Sigma X F$$

می دانیم که طرف اول این معادله معکوس می توان نوشت در معادله معکوس می توان نوشت  $F$  می توان نوشت در معادله معکوس می توان نوشت

$$(X^T X) X^T Y = (X^T \Sigma^{-1} X)^{-1} X^T \Sigma^{-1} Y$$

ماتریس  $F$  nonsingular است در نتیجه معکوس می توان نوشت در معادله معکوس می توان نوشت

$$\sum X \Sigma X F \rightarrow \Sigma^{-1} X \Sigma X F \rightarrow X^T \Sigma^{-1} (F^{-1})^T X^T$$

$$\rightarrow (F^{-1})^T X^T X (F^{-1})^T X^T Y = (X^T X)^{-1} F^T (F^{-1})^T X^T Y$$

در این معادله معکوس می توان نوشت

$$L_1 = \sum_{n=1}^N (y_n - w^T x_n)^2 + \sum \lambda w$$

(d) می توان نوشت



این مسئله معادله‌ای است که می‌توانیم آن را به شکل  $\lambda x = \lambda I x + x$  بنویسیم. در این معادله،  $\lambda$  مقدار اسکالر و  $x$  بردار است. این معادله را می‌توانیم به شکل  $(\lambda I - A)x = x$  بنویسیم. در این معادله،  $\lambda$  مقدار اسکالر و  $x$  بردار است. این معادله را می‌توانیم به شکل  $(\lambda I - A)x = x$  بنویسیم.

$$|y - x|^2$$

در این معادله،  $\lambda$  مقدار اسکالر و  $x$  بردار است. این معادله را می‌توانیم به شکل  $(\lambda I - A)x = x$  بنویسیم. در این معادله،  $\lambda$  مقدار اسکالر و  $x$  بردار است. این معادله را می‌توانیم به شکل  $(\lambda I - A)x = x$  بنویسیم.

$$|y - (\sqrt{\lambda} I + x)|^2 + \lambda \|x\|^2$$

$$q(x) = N(x|\mu, \Sigma) \Rightarrow Q = (2\pi)^{-k/2} \det(\Sigma)^{-1/2} e^{-1/2(x-\mu)^T \Sigma^{-1}(x-\mu)}$$

سوال ۳: طبق تعریف  $Q$  داریم:

$$KL(P||Q) = \int P(x) \log \frac{P(x)}{Q(x)} dx = \int P(x) \log P(x) dx - \int P(x) \log Q(x) dx$$

$$E_P[x] = \mu = \int x P(x) dx, \quad \Sigma = \text{Var}_P(x)$$

می‌فرضیم تابع  $P(x)$  یک تابع چگالی احتمال است. در این معادله،  $\mu$  میانگین و  $\Sigma$  واریانس است. این معادله را می‌توانیم به شکل  $(\lambda I - A)x = x$  بنویسیم.

$$\int P(x) \log P(x) dx - \int P(x) \log (2\pi)^{-k/2} dx - \int P(x) \log \det(\Sigma^{-1/2}) dx -$$

$$\int P(x) \log e^{-1/2(x-\mu)^T \Sigma^{-1}(x-\mu)} dx$$

$$\rightarrow \int P(x) \log P(x) dx + \frac{k}{2} \int P(x) (\log 2\pi) dx + \frac{1}{2} \int P(x) \log (\det \Sigma) dx$$

$$+ \int P(x) \frac{1}{2} (x-\mu)^T \Sigma^{-1} (x-\mu) dx = A$$

در این معادله،  $\mu$  میانگین و  $\Sigma$  واریانس است. این معادله را می‌توانیم به شکل  $(\lambda I - A)x = x$  بنویسیم.

$$\rightarrow \frac{dA}{d\Sigma} = \frac{1}{2} \left( \int P(x) \left[ \frac{d}{d\Sigma} \log \det(\Sigma) + (x-\mu)^T \Sigma^{-1} (x-\mu) \right] dx \right)$$

$$= \frac{1}{2} \int P(x) \left[ \frac{1}{\Sigma} - \frac{1}{\Sigma^2} (x-\mu)^T (x-\mu) \right] dx \rightarrow \frac{1}{2\Sigma} = \frac{1}{2\Sigma^2} \int P(x)$$

$$(x-\mu)^T (x-\mu) dx \rightarrow \Sigma = \int P(x) (x-\mu)^T (x-\mu) dx = \Sigma = \text{Var}_P(x)$$

این معادله را می‌توانیم به شکل  $(\lambda I - A)x = x$  بنویسیم.



$$\frac{dA}{d\mu} = \frac{1}{T} \int P_n \frac{d}{d\mu} \left[ (n-\mu)^T \Sigma (n-\mu) \right] d\mathbf{n} = \frac{1}{T} \int P_n \left[ \right]$$

$$d\mathbf{n} = \frac{V^M}{V} = \int \rho_n (-\mathbf{n} \cdot \mathbf{n}^T) d\mathbf{n} \rightarrow M, \int \rho_n \mathbf{n} d\mathbf{n}$$

$$E = \sum_{n=1}^N (y_n - w_n^T x_n)^2$$
$$1 \sum_{n=1}^N (y_n - w_n^T x_n) x_n \rightarrow \sum_{n=1}^N y_n x_n - w^T \sum_{n=1}^N x_n x_n^T$$

در این معادله ماتریس  $X^T X$  و  $X^T y$  را می‌توان به صورت زیر نوشت:

مجلس

$$\rightarrow x_j^T y - x_j^T x_j w \rightarrow w = \frac{x_j^T y}{x_j^T x_j}$$

$$X^T y, (X^T X) w$$

(b) سنجش های خنک کننده ای  $x_i^T x_j \leq 0$

$$\rightarrow w = (X^T X)^{-1} X^T y$$

$$\begin{bmatrix} x_1^1 & x_1^r & \dots & x_1^n \\ x_r^1 & x_r^r & \dots & x_r^n \\ \vdots & \vdots & \ddots & \vdots \\ x_n^1 & x_n^r & \dots & x_n^n \end{bmatrix} \begin{bmatrix} x_1^1 & x_1^r & \dots & x_1^n \\ x_r^1 & x_r^r & \dots & x_r^n \\ \vdots & \vdots & \ddots & \vdots \\ x_n^1 & x_n^r & \dots & x_n^n \end{bmatrix} = \begin{bmatrix} x_1^T x_1 + 0 \\ x_r^T x_r + 0 \\ \vdots \\ x_n^T x_n + 0 \end{bmatrix} = X^T X$$

خودانه - ۱ - انما یقیم بر یک ی سوار

$$\rightarrow W = (X^T X)^{-1} X^T Y = \frac{X_1 Y}{X_1^T X_1} + \frac{X_2 Y}{X_2^T X_2} + \dots + \frac{X_n Y}{X_n^T X_n}$$

که همان حاصل جمع ضرایب است.

(c) در یک سیستم خطی و همبسته، اگر ورودی و خروجی به صورت زیر باشد:

$$E = \sum_{n=0}^N (y - w^T x_n)^2$$

می‌خواهیم  $w$  را پیدا کنیم که خطای کمینه شود  
و  $w$  به صورت زیر است:

$$\frac{dE}{dw_0} \rightarrow 2 \sum (y - w^T x_n) x_{n0}$$

$$\rightarrow \sum y x_{n0} - w^T \sum x_n x_{n0} \rightarrow x_0^T y = w_0 n + w_j x_0^T x_j$$

نقطه در مقدار دارد

$$\rightarrow w_0 = \frac{x_0^T y - w_j x_0^T x_j}{n} \xrightarrow{\text{مقدار میانی}} E(y) - w_j E(x_j)$$

$$\frac{dE}{dw_j} \rightarrow \sum y x_{nj} - w^T \sum x_n x_{nj} \rightarrow x_j^T y = w_0 x_0^T x_j + w_j x_j^T x_j$$

مقدار میانی

$$\rightarrow n x_j^T y = [x_0^T y - w_j x_0^T x_j] x_0^T x_j + n w_j x_j^T x_j$$

$$= x_0^T y x_0^T x_j - w_j x_0^T x_j x_0^T x_j + n w_j x_j^T x_j \rightarrow$$

$$n x_j^T y = (x_0^T y)^2 - w_j [(x_0^T x_j)^2 - n x_j^T x_j] \rightarrow$$

$$w_j = \frac{(x_0^T y)^2 - n(n^T y)}{(x_0^T x_j)^2 - n x_j^T x_j} \rightarrow w_j = \frac{\text{cov}(x_j, y)}{\text{var}(x_j)}$$